


Diseño e Implementación de la Base de Datos Operacional (OLTP) e Infraestructura en Azure

Construcción del módulo comercial OLTP: Un módulo comercial OLTP es un sistema informático diseñado con el objetivo de gestionar, registrar y ejecutar grandes cantidades de transacciones comerciales concurrentes.

En este proyecto vemos el caso de una empresa minorista con varias sedes en Colombia que actualmente tiene datos transaccionales en una base de datos relacional (OLTP) y archivos CSV para registrar información complementaria.

A continuación podemos ver un diagrama entidad relación de la base de datos relacional implementada (este también se encuentra dentro de la carpeta docs en el repositorio):



- **Decisiones de diseño del modelo relacional:** A continuación, justificamos algunas decisiones tomadas respecto al diseño de esta base de datos:
 - **Normalización 3FN:** Se aplicó el estándar de diseño de la tercera forma normal para eliminar redundancias, optimizar el tamaño, evitar inconsistencias, y simplificar los aspectos de la base de datos.

- **Tablas opcionales agregadas:** Aunque se proponen unas 13 tablas mínimas para esta base de datos, decidimos implementar dos más que pensamos que podían enriquecer el proyecto:
 - **CampañasComerciales:** Es una tabla que representa campañas realizadas por la empresa con el objetivo de promocionar las tiendas y sus productos.
 - **CanalVenta:** Tabla que representa los diferentes medios por los cuales las tiendas pueden realizar ventas (físico, web, etc.)
- **Criterio detrás de decisiones específicas:** Esta es la justificación detrás de algunas de las decisiones “menos obvias” que tomamos para el diseño del modelo:
 - **Subtotal:** En DetalleVentas y DetalleCompras, la columna “Subtotal” se calcula automáticamente en base a la cantidad de unidades y el precio por unidad. Esto para evitar errores humanos que pueden ocurrir si este campo fuese ingresado manualmente.
 - **StockFinal:** En la tabla InventarioDiario, se verifica que la columna “StockFinal” sea equivalente al stock inicial del día + el stock entrante - el stock saliente, con el objetivo de prevenir que un error humano en el cálculo llegue a quedar registrado en la base de datos.
 - **CampañaComercial puede ser NULL en Ventas:** En la tabla Ventas hay una columna llamada “IdCampañaComercial” en la cual puede haber una ID sujeta a una campaña comercial alrededor del producto. Este campo puede ser opcional ya que no todos los productos comerciales tienen campañas que los promocionan activamente.
 - **Inclusión de índices analíticos en el OLTP:** Hay implementaciones en las que se esperaría que estos índices se encuentren en el DW y no en el OLTP, pero esta es una decisión con el fin de acelerar el proceso de carga. Ponerlos en el OLTP los JOINS del ETL para extraer los datos.
- **Diccionario de Datos:** Este diccionario de datos cubre las tablas, los índices, y las fuentes externas CSV. Por cada tabla en la base de datos, se muestra cada columna por nombre, tipo de dato, restricciones y descripción. Por cada fuente externa (CSV), se muestra cada columna por nombre, tipo y descripción. Y por cada índice, se muestra cada uno por nombre, tabla en el que aplica, columnas en el que aplica, tipo y propósito.

- **Fuentes Externas:** Hay dos archivos CSV que se utilizan para simular la ingesta de datos desde un medio diferente al SQL, y para hacer ajustes a una tabla desde este archivo:
 - **metas_mensuales.csv:** Es la que ingesta los datos de la tabla “MetasComerciales”, cuenta con las columnas Año, Mes, TiendaID, NombreTienda, CategoriadID, NombreCategoria, ValorMeta. Los nombres no son idénticos a los de la tabla “MetasComerciales” e incluso hay columnas que no son mencionadas en la tabla, pero el objetivo es demostrar la adaptación de los datos de este formato CSV a la base de datos SQL.
 - **inventario_ajustes.csv:** Representa una fuente externa de ajustes manuales de inventario, producto de conteos físicos realizados en las tiendas. Cuenta con las columnas Año, Mes, TiendaID, NombreTienda, ProductoID, StockFisico, StockSistema, Ajuste y Motivo. Este archivo no ingesta datos directamente a ninguna tabla del OLTP, sino que sirve como insumo para la zona de staging, donde será utilizado para detectar y documentar discrepancias entre el stock registrado en el sistema y el stock contado físicamente, como parte del proceso de validación de calidad de datos.
- **Estrategia de generación de datos sintéticos:** A continuación podemos ver un caso de la generación de datos sintéticos con el Script que tenemos para ello:

	(No column name)	(No column name)
1	Categorias	12
2	Proveedores	5
3	Tiendas	10
4	CanalVenta	4
5	CampañasComerciales	6
6	Clientes	1500
7	Productos	250
8	Vendedores	25
9	Ventas	50000
10	DetalleVentas	249448
11	Compras	2500
12	DetalleCompras	11257
13	InventarioDiario	230479
14	Devoluciones	2500

(Tomar en cuenta que MetasComerciales se carga a partir de la fuente externa que sería el archivo CSV para ello)

Como se puede observar, se cumplen los requisitos mínimos solicitados en relación al volumen de datos del que se debe disponer, e incluso hay tablas con más registros con solo el mínimo. Esto se diseñó de tal manera para que hubiera un mejor equilibrio entre los datos considerando que es un caso que busca ser lo más realista posible. Hay también tablas con una cantidad de filas que puede variar entre ejecuciones del Script de generación de los datos, como lo son DetalleVentas, DetalleCompras, o InventarioDiario. Esto ya que son valores que suelen ser menos predecibles y varían bastante con respecto a las condiciones de la actividad de la empresa. De todas maneras, se diseñó el código con el propósito de que estos registros no bajen del volumen solicitado.

- **Implementación en la nube del SQL Server:** La implementación de la máquina virtual en la nube de Azure no fue posible, esto ya que no hay ninguna región que cuente con imágenes o tamaños para la VM disponibles con el plan que tienen nuestras cuentas institucionales, problema compartido por otros compañeros del curso. Se contempló la idea de realizar esta implementación con el servicio de Amazon Web Services RDS, pero el AWS Learner Lab que se nos es dado como estudiantes cuenta con la desventaja de apagarse manualmente cada 4 horas, lo cual resultaría extremadamente impráctico para una disponibilidad constante en la nube de la base de datos.

Diseño e Implementación de staging, Data Warehouse y ETL

Arquitectura general de la solución BI

Capa	Base de datos	Propósito
Origen	BI_OLTP	Sistema transaccional. 15 tablas, 50.000 ventas, ~150.000 líneas.
Staging	BI_Staging	Zona intermedia. Recibe datos crudos, aplica validaciones de calidad y deja registros marcados como VÁLIDO o RECHAZADO.
Analítico	BI_DW	Data Warehouse dimensional. Modelo estrella con 9 dimensiones y 6 tablas de hechos. Fuente del modelo semántico de Power BI.

El flujo de datos es unidireccional: BI_OLTP → BI_Staging → BI_DW → Power BI. El DW nunca lee directamente del OLTP; todo pasa por Staging para garantizar trazabilidad y control de calidad.

Base de datos de Staging (BI_Staging)

La zona de Staging existe porque el Data Warehouse requiere datos limpios, consistentes y con claves resueltas, pero las fuentes de origen (el OLTP y los archivos CSV externos) no garantizan esa calidad. El Staging es el espacio donde se reciben los datos tal como están, se detectan los problemas y se toman decisiones explícitas sobre cada registro antes de que llegue al DW.

Las reglas de diseño aplicadas son tres:

- Sin claves foráneas entre tablas STG, tipos de dato amplios y campos de auditoría en cada tabla.

Tablas implementadas

- STG_Ventas
- STG_Productos
- STG_Clientes
- STG_Inventario
- STG_Devoluciones
- STG_Compras
- STG_Metas
- STG_AjustesInventario
- ETL_Log

Inconsistencias detectadas y resueltas

Al integrar las fuentes externas CSV con el OLTP se identificaron dos inconsistencias estructurales que fueron resueltas en el ETL:

Nombres de categoría distintos entre el CSV y el OLTP.

El archivo metas_mensuales.csv usa nombres de categoría que no coinciden con los del OLTP. Por ejemplo, el CSV usa “Electrónica” mientras el OLTP tiene “Tecnología”, o el CSV usa “Ropa y Moda” mientras el OLTP tiene “Moda y Calzado”. Esto generaría muchos registros no mapeados si no se resuelve. La solución implementada es una tabla de homologación explícita dentro de sp_ValidarStaging que traduce cada nombre del CSV al nombre oficial del OLTP. El mapeo se guardó en dos columnas separadas: NombreCategoria_CSV y CategoricalID_Resuelto.

Registros con Ajuste = 0 en el CSV de inventario.

El archivo inventario_ajustes.csv contiene 17 registros donde el campo Ajuste vale cero, es decir, el conteo físico coincidió exactamente con el sistema. Estos registros no

tienen impacto analítico (no modifican ningún stock) y fueron marcados como RECHAZADO en Staging con el mensaje descriptivo “Ajuste = 0, registro sin impacto analítico”. Esta decisión se tomó conscientemente y se documenta aquí como evidencia de validación.

Data Warehouse dimensional (BI_DW)

Modelo en estrella vs. copo de nieve

Se implementó un modelo en estrella (Star Schema). La decisión de no usar copo de nieve se basa en que el modelo estrella produce consultas más simples para Power BI (menos JOINS en el motor), mejor rendimiento en lecturas analíticas y mayor claridad conceptual. La única excepción es DimGeografia, que actúa como tabla de referencia compartida entre DimCliente, DimTienda y DimProveedor, lo cual evita redundancia de Ciudad/Región sin romper la simplicidad del modelo.

Las 6 tablas de hechos y su granularidad

La granularidad es la decisión más crítica del modelo dimensional. Define qué representa exactamente una fila en cada tabla de hechos y determina qué preguntas puede responder el modelo.

Medidas aditivas, semi-aditivas y no aditivas

Una medida es aditiva cuando tiene sentido sumarla en cualquier dirección (por fecha, por tienda, por producto). Es semi-aditiva cuando solo tiene sentido sumarla en algunas dimensiones. Es no aditiva cuando sumar sus valores nunca produce un resultado significativo.

- **Medidas aditivas:** MontoVenta, MontoCosto, MargenBruto, Cantidad, UnidadesEntrantes, UnidadesSalientes, ValorMeta, MontoCompra, MontoDevuelto. Se pueden agregar por cualquier combinación de dimensiones.
- **Medidas semi-aditivas:** StockInicial, StockFinal, StockPromedio. Son válidas para sumar a través de tiendas en un mismo día (stock total del negocio ese día), pero no a través del tiempo (el stock del lunes más el stock del martes no da un total útil).
- **Medidas no aditivas:** PrecioUnitario, MargenPorcentaje. Sumar precios unitarios de líneas distintas o sumar porcentajes de margen de productos distintos no produce un número significativo. En Power BI se calculan con DIVIDE sobre medidas aditivas.

SCD Tipo 2 — Slowly Changing Dimensions

Se implementó SCD Tipo 2 en DimCliente y DimProducto porque ambas dimensiones tienen atributos que pueden cambiar a lo largo del tiempo y cuyo valor histórico es relevante para el análisis. Si un cliente cambia de segmento o ciudad, o si un producto cambia de precio, se necesita saber en qué estado estaba ese atributo en el momento de cada transacción.

En la carga de FactVentas, la resolución de la surrogate key de cliente y producto se hace buscando la versión vigente a la fecha exacta de la venta. Esto garantiza que cada transacción histórica quede vinculada al precio y al segmento de cliente que tenía en ese momento, no al valor actual.

Surrogate Keys y diferencias con el OLTP

Cada dimensión tiene su propia clave sustituta (surrogate key) generada por IDENTITY, completamente independiente de los IDs del OLTP. El motivo es triple: el OLTP puede reutilizar o cambiar sus IDs, el SCD Tipo 2 necesita múltiples filas para el mismo ID OLTP (una por versión), y el desacoplamiento permite evolucionar el OLTP sin impactar el DW. El ID original del OLTP se conserva en columnas de sufijo _OLTP (ej. ClienteID_OLTP) exclusivamente para trazabilidad en el ETL.

Procesos ETL en T-SQL

Arquitectura del pipeline

El pipeline ETL se estructura en 5 fases secuenciales coordinadas por el procedimiento sp_OrquestadorPipeline. Cada fase depende del éxito de la anterior; si cualquier procedimiento falla, el orquestador detiene la ejecución, registra el fallo en ETL_Log con el nombre exacto de la fase que falló y el mensaje de error, y no continúa hacia las fases siguientes.

Validación y calidad de datos

El pipeline completo se ejecutó con el comando EXEC BI_DW.dbo.sp_OrquestadorPipeline desde SQL Server Management Studio.

	TablaStaging	TotalRegistros	Validos	Rechazados	TasaRechazo_Pct
1	STG_Metas	960	720	240	25.00
2	STG_AjustesInventario	120	103	17	14.17
3	STG_Clientes	1500	1500	0	0.00
4	STG_Compras	11153	11153	0	0.00
5	STG_Devoluciones	2500	2500	0	0.00
6	STG_Inventario	226295	226295	0	0.00
7	STG_Productos	250	250	0	0.00
8	STG_Ventas	250394	250394	0	0.00

	TablaStaging	STG_MensajeError	CantidadRechazados
1	STG_AjustesInventario	Ajuste = 0, registro sin impacto analítico	17
2	STG_Metas	Categoría del CSV no mapeada a OLTP	240

	TablaHechos	TotalFilas
1	FactVentas	250394
2	FactInventarioDiario	226306
3	FactMetasComerciales	720
4	FactDevoluciones	2547
5	FactCompras	11153
6	FactRentabilidad	62917

Nota sobre los rechazos de STG_Metas: los 240 registros rechazados corresponden a combinaciones de categoría del CSV cuyo nombre no tiene equivalente en el catálogo actual del OLTP, incluso después de aplicar la tabla de homologación. Esto significa que el CSV de metas cubre categorías que no existen en la BD operacional en su versión actual. Los 720 registros válidos son suficientes para el análisis de cumplimiento de metas en Power BI.

Diseño e Implementación del Modelo Semántico, Medidas DAX y Dashboard en Power BI

Construcción de la capa de visualización

La capa de visualización es la cara final del sistema BI ante los usuarios del negocio. Toma el Data Warehouse como insumo y lo expone como un modelo semántico interactivo, con medidas analíticas precalculadas y un dashboard navegable. En este proyecto, la capa de visualización fue construida en Microsoft Power BI Desktop y publicada en Power BI Cloud con enlace de acceso público.

Conexión al Data Warehouse y modo de carga

La conexión al DW se configuró en modo Importar (no DirectQuery). La decisión obedece a tres razones: las consultas se resuelven en memoria del motor VertiPaq, lo cual entrega tiempos de respuesta inmediatos al usuario; el dashboard queda desacoplado del estado del servidor SQL, permitiendo que funcione incluso si el motor está apagado; y el modo importado es compatible con todas las funciones DAX, incluidas las de time intelligence que dependen de la tabla de fechas marcada.

Modelo semántico

A partir de las 15 tablas del DW (9 dimensiones y 6 hechos), Power BI autodetectó las relaciones uno-a-muchos basándose en las llaves foráneas explícitas del diseño. Sin embargo, cuatro relaciones quedaron inactivas por rutas ambiguas, las cuales fueron resueltas manualmente según criterios analíticos del negocio:

FactVentas a DimGeografia: existían dos rutas posibles, vía DimCliente o vía DimTienda. Se priorizó la ruta vía DimTienda, desactivando la relación DimCliente-DimGeografia, porque en análisis comerciales la geografía relevante es donde físicamente ocurre la venta, no la dirección de residencia del cliente.

FactCompras a DimProveedor: presentaba ambigüedad por una ruta indirecta vía DimGeografia. Se resolvió desactivando la relación DimProveedor-DimGeografia, conservando la conexión directa al proveedor.

FactVentas a DimVendedor: tenía conflicto con la ruta indirecta FactVentas-DimTienda-DimVendedor. Se priorizó la relación directa al vendedor, desactivando la conexión DimVendedor-DimTienda, para permitir análisis independiente del desempeño individual.

FactDevoluciones a DimFecha: la tabla contiene dos referencias a fecha (fecha de devolución y fecha de venta original). Se mantuvo activa la relación con la fecha de devolución, dejando inactiva la de venta original para usar puntualmente con USERELATIONSHIP en medidas específicas si fuera necesario.

DimFecha marcada como tabla de fechas: La columna Fecha de DimFecha fue marcada como tabla de fechas oficial del modelo. Esto es un prerrequisito técnico para que las funciones de time intelligence (SAMEPERIODLASTYEAR, TOTALYTD, DATEADD, DATESINPERIOD) operen correctamente. Sin esta configuración, Power BI usaría sus tablas internas de fechas autogeneradas, lo cual genera inconsistencias con el calendario fiscal del DW.

Jerarquías construidas: Se construyeron cuatro jerarquías para habilitar operaciones OLAP de drill-down y roll-up:

Jerarquía Tiempo (DimFecha): Año → NombreTrimestre → NombreMes → Fecha
Jerarquía Geografía (DimGeografia): Pais → Region → Ciudad
Jerarquía Producto (DimProducto): NombreCategoria → NombreProducto
Jerarquía Tienda (DimTienda): Region → Ciudad → NombreTienda

Estas jerarquías son las que permiten la navegación multinivel exigida en la página de exploración OLAP del dashboard.

Tabla de medidas

Se creó una tabla vacía llamada _Medidas (prefijo de guión bajo para que aparezca al inicio del panel de campos) que funciona como contenedor de las 29 medidas DAX. La columna técnica de la tabla se ocultó del informe. Este patrón es estándar en proyectos profesionales de Power BI porque separa visualmente las medidas calculadas de las columnas físicas de las tablas, facilitando la navegación.

Medidas DAX implementadas: Se implementaron 29 medidas (el mínimo exigido era 15), organizadas en siete categorías temáticas:

Base de ventas: Total Ventas, Total Costo, Utilidad Bruta, Margen Bruto Porcentaje.
Time intelligence: Ventas Año Anterior, Crecimiento Porcentaje, Ventas YTD, Ventas Mes Anterior, Variación Mensual Porcentaje.
Cumplimiento de metas: Total Meta, Cumplimiento Meta Porcentaje, Brecha Meta, Semáforo Meta.
Ranking y participación: Ranking Productos, Ranking Tiendas, Participación Porcentaje Producto.
Comportamiento comercial: Ticket Promedio, Cantidad de Ventas, Unidades Vendidas, Promedio Móvil 3 Meses.
Inventario: Stock Actual, Inventario Promedio, Rotación Inventario, Días de Inventario.
Devoluciones, compras y rentabilidad: Total Devoluciones, Tasa Devolución Porcentaje, Cantidad Devoluciones, Total Compras, Margen Rentabilidad Porcentaje.

Tratamiento de medidas semi-aditivas

Las medidas de inventario merecen mención especial. StockInicial y StockFinal son semi-aditivas: pueden sumarse a través de productos y tiendas en una misma fecha, pero no a través del tiempo. La medida Stock Actual usa el patrón clásico de tomar la última fecha disponible mediante CALCULATE con LASTDATE. La medida Inventario Promedio usa el patrón AVERAGEX sobre VALUES de DimFecha, calculando el stock total por día y luego promediando esos totales en el tiempo. Aplicar SUM directamente a StockFinal sin estos patrones daría resultados sin sentido analítico.

Decisión metodológica en métricas de rotación

Las medidas Rotación Inventario y Días de Inventario fueron reformuladas durante el desarrollo. La primera versión calculaba rotación como Total Costo dividido Inventario Promedio, pero el resultado era absurdo porque mezclaba unidades monetarias (pesos colombianos del costo) con unidades físicas (cantidad de productos en stock). Se reformularon usando Unidades Vendidas como numerador, manteniendo coherencia en las unidades. En un proyecto real, la recomendación al equipo de ETL sería incorporar una columna de valor monetario del inventario en FactInventarioDiario para permitir análisis financiero completo.

Dashboard de seis páginas

El dashboard se estructuró en seis páginas, cada una con un propósito analítico específico:

Página 1, Ejecutivo: vista panorámica para gerencia con cuatro KPIs principales (ventas totales, utilidad bruta, margen porcentual, cumplimiento de meta), tendencia mensual comparada año contra año, y rankings Top 5 de tiendas y productos.

Página 2, Análisis de Ventas: cinco segmentadores en cascada (Año, Trimestre, Mes, Tienda, Canal), gráfico combinado de barras y línea para ventas y ticket promedio, donut de participación por canal, treemap de categorías, tabla de desempeño por vendedor y mapa de ventas por ciudad.

Página 3, Inventario: KPIs de stock actual, inventario promedio, rotación y días de inventario; evolución temporal del stock; tablas de productos con menor rotación y de alertas de stock crítico con formato condicional.

Página 4, Rentabilidad: comparación de ingresos contra costos por categoría; gráfico de dispersión Volumen vs Margen por producto con cuatro cuadrantes estratégicos; heatmap de margen bruto por tienda y categoría con formato condicional rojo-amarillo-verde.

Página 5, Cumplimiento de Metas: KPIs de ventas reales, meta total y brecha con formato condicional verde-rojo; medidor (gauge) de cumplimiento del período; barras horizontales de cumplimiento por tienda con línea de referencia al 100%; matriz Real vs Meta con drill-down de Tienda a Categoría y columna de semáforo.

Página 6, Exploración OLAP: página específica para demostrar las cuatro operaciones OLAP fundamentales: SLICE mediante segmentadores individuales (Año, Región, Canal, Categoría), DICE mediante combinación simultánea de filtros, DRILL-DOWN en

la matriz con jerarquía de tiempo (Año → Trimestre → Mes → Fecha) y ROLL-UP en el treemap con jerarquía geográfica (Región → Ciudad → Tienda).

Publicación y entrega

El dashboard fue publicado a Power BI Cloud bajo "Mi área de trabajo" usando cuenta institucional EAFIT, y posteriormente expuesto mediante la función "Publicar en la Web" para generar un enlace público de acceso sin necesidad de autenticación. Esto permite al evaluador y a cualquier persona con el enlace visualizar e interactuar con el dashboard desde cualquier navegador.

Utilización de Inteligencia Artificial en este Proyecto

- Para el diseño de la base de datos OLTP, lo cual viene siendo la definición de las columnas por cada tabla, relaciones con demás tablas y selección de tablas opcionales a utilizar, se usó un 10% de inteligencia artificial, con el propósito de validar la practicidad del diseño planteado y recoger Feedback de este.
- Para la creación de los Scripts SQL encargados de la creación del OLTP y de la generación de datos sintéticos se utilizó un 98% de inteligencia artificial, ya que esta se encargó de la generación del código en estos archivos. El 2% restante corresponde a la verificación manual de consistencia en los datos.
- Para la creación de los archivos CSV que funcionan como fuentes externas se usó un 90% de IA. El 10% restante corresponde a la planeación de las columnas de los CSV, la generación de las filas fue trabajo de la inteligencia artificial.
- El diccionario de datos fue 70% inteligencia artificial, el 30% restante corresponde a la definición de las columnas de cada tabla, la cual se dio durante el diseño de la base de datos OLTP. El trabajo de la IA fue abastecer los aproximadamente 114 datos catalogados aquí, en consistencia con los archivos.
- En el desarrollo de la capa de Staging, Data Warehouse y el pipeline de orquestación en T-SQL, se utilizó la Inteligencia Artificial de forma estratégica como una herramienta de aceleración para el código base y estructural. Específicamente, la IA facilitó la generación de los esqueletos iniciales de las tablas analíticas, la estructura genérica del modelo en estrella y la plantilla repetitiva de captura de excepciones en los bloques TRY/CATCH para la bitácora ETL_Log. Esta asistencia automatizada permitió optimizar los tiempos de desarrollo en tareas operacionales del "camino ideal" del flujo de datos, sirviendo como un asistente de sintaxis de alta velocidad.
- Sin embargo, la resolución de la complejidad analítica del negocio recayeron por completo en el criterio humano nuestro. La IA fue incapaz de prever los problemas operativos reales del proyecto, tales como el desfase de fechas históricas que bloqueaba el cruce de dimensiones SCD Tipo 2, las colisiones sintácticas de los comandos BULK INSERT locales o la inconsistencia en el mapeo de categorías entre los CSV externos y el OLTP. La definición de las granularidades atómicas y derivadas y el diseño de alertas para aislar registros sin impacto analítico fueron decisiones nuestras. El pipeline funcional y validado es el resultado directo de la comprensión conceptual y el control de calidad ejercido por el equipo.
- Para el diseño del modelo semántico en Power BI (relaciones entre las 15 tablas, jerarquías de tiempo, geografía, producto y tienda, y resolución de cuatro relaciones ambiguas que Power BI dejó inactivas por defecto) se usó aproximadamente un 40% de inteligencia artificial, principalmente para consultar

conceptos sobre rutas de filtro y cardinalidad. El 60% restante corresponde a la decisión propia sobre qué ruta mantener activa en cada ambigüedad, basada en criterios analíticos del negocio.

- Para la generación de las 29 medidas DAX se utilizó aproximadamente un 85% de inteligencia artificial, ya que esta produjo las versiones iniciales del código de cada medida. El 15% restante corresponde a la validación funcional en el entorno real, la corrección de medidas con nombres de columnas incorrectos al confrontarlas contra el script real del DW, y la reformulación de medidas semi-aditivas como Rotación de Inventario y Días de Inventario que en su primera versión daban resultados absurdos por mezclar unidades monetarias con unidades físicas.
- Para el diseño visual de las seis páginas del dashboard (sugerencias de tipos de visual por KPI, distribución preliminar de cada página, propuestas de paleta y formato) se usó aproximadamente un 40% de inteligencia artificial. El 60% restante corresponde al armado físico de los visuales en Power BI Desktop, su posicionamiento, formato condicional, configuración de jerarquías para drill-down y roll-up, y validación cruzada de coherencia entre páginas.